

基于对抗训练和注意力机制的MOOC评论方面词抽取

贾灿, 艾孜尔古丽

(新疆师范大学, 新疆 乌鲁木齐 830054)

摘要: 针对复杂语境下MOOC在线评论中常见的实体分布不均衡、边界模糊及语义关联不足等问题, 本文提出了一种结合对抗训练与注意力机制的方面词抽取方法。首先, 基于RoBERTa-WWM预训练模型提取动态词向量, 并通过对抗训练生成扰动样本, 将其融入嵌入层, 以有效缓解数据不平衡问题。其次, 在特征提取阶段引入多头自注意力机制, 优化BiLSTM提取的序列特征, 进一步增强模型对文本边界信息和语义关联的捕捉能力。最后, 采用条件随机场对标签序列进行解码。实验结果表明, 该方法在MOOC评论数据集上的F1值较最优基线模型提升了2.45%, 有效提高了识别精度, 适用于MOOC评论领域的方面词抽取任务。

关键词: MOOC; 方面词抽取; RoBERTa; 对抗训练; 注意力机制; 条件随机场

中图分类号: G642 **文献标识码:** A

文章编号: 1009-3044(2025)10-0009-05

DOI: 10.14004/j.cnki.ckt.2025.0502

开放科学(资源服务) 标识码(OSID):



0 引言

MOOC(大规模开放在线课程)已成为现代教育的重要组成部分, 推动了知识传播和终身学习。如何从快速增长的课程内容和评论数据中提取有效信息, 提升学习体验成为一大挑战。课程评论不仅反映学生的情感反馈, 还揭示了教学内容、资源质量和学习难度等问题。通过精确的方面词抽取, 可以为优化课程内容、改进教学策略和提升学习体验提供依据。因此, 研究高效的方面词抽取方法, 不仅能提高情感分析的准确性, 也有助于个性化学习和教育服务质量的提升。

随着在线教育质量与学习体验的关注度不断提升, 以及人工智能技术的迅速发展, MOOC智能化研究成为热点领域。潘芳等人^[1]基于BERT框架实现课程评论的特征抽取, 有效提升了抽取精度; Chen等人^[2]提出融合多语言知识的图神经网络, 增强了隐式情感分析能力; Bai等人^[3]结合BERT-BiLSTM模型提取MOOC视频语义特征, 优化了依赖关系建模。尽管预训练模型和深度学习方法在MOOC评论特征抽取中取得了显著进展, 但在处理噪声数据、长距离依赖及语义一致性问题仍存在不足。

为克服上述局限性, 本文提出一种融合对抗训练与注意力机制的方面词抽取模型, 主要工作包括: 首先, 通过爬取慕课平台中软件工程、计算机网络等7门课程的评论数据, 构建领域数据集; 其次, 采用RoBERTa-WWM预训练模型结合BiLSTM-CRF策略进行实体抽取, 并通过对抗训练在RoBERTa-WWM生成的字向量上引入对抗扰动, 增强模型对领域语义

的解析能力; 同时, 将BiLSTM提取的序列特征输入多头自注意力网络, 基于字词的重要性分配不同权重, 强化句中字词间的语义关联。该方法有效缓解了MOOC语料中的数据不平衡和实体边界模糊问题, 显著提升了模型的鲁棒性和实体识别性能。

本文的创新点和贡献如下: (1) 创新点: 提出了一种结合对抗训练与多头自注意力机制的方面词抽取模型, 增强了模型的语义解析与鲁棒性。 (2) 贡献: 构建了一个涵盖多个课程的大规模MOOC评论数据集, 为MOOC评论分析提供了宝贵的数据资源; 通过融合对抗训练和注意力机制, 显著提升了模型对长距离依赖、噪声数据和模糊实体边界的处理能力; 实验结果验证了该方法在方面词抽取中的优越性, 为MOOC评论分析提供了新的研究思路。

1 相关工作

1.1 方面词抽取

方面词抽取是命名实体识别(NER)任务的具体化, 旨在从文本中识别具有特殊指代意义的词汇。命名实体识别通过各类算法从文本中提取这些实体^[4]。Huang等人^[5]首次将BiLSTM应用于上下文特征结合, 并成功将BiLSTM-CRF模型用于序列标注任务, 验证了其在NER训练中的有效性和鲁棒性。Liu等人^[6]则将BERT-BiLSTM-CRF模型应用于非结构化历史文本的实体提取, 并在历史文化领域取得了显著成果。目前, 方面词抽取方法主要基于深度学习技术, 结合预训练语言模型、注意力机制和序列标注等手段, 持

收稿日期: 2024-11-10

基金项目: 新疆维吾尔自治区创新环境(人才、基地)建设专项-自然科学计划(少数民族科技人才特殊培养)项目(2022D03001); 新疆师范大学青年拔尖人才资助项目(XJNUQB2022-22); 新疆师范大学智慧教育工程技术研究中心招标课题(XJNU-ZHJY202403); 国家自然科学基金项目(61662081); 国家社会科学基金项目(14AZD11)

作者简介: 贾灿(2000—), 女, 山东枣庄人, 硕士研究生, 研究方向为MOOC情感分析; 艾孜尔古丽(1987—), 女, 新疆乌鲁木齐人, 通信作者, 博士, 副教授, 研究方向为自然语言处理舆情分析。

续优化模型性能。这些研究为进一步提升方面词抽取效果提供了重要的理论依据。

1.2 对抗训练

对抗训练最初应用于计算机视觉领域^[7],通过在训练样本中加入细微扰动,增强模型的适应性与鲁棒性,以应对复杂环境。近年来,其优势逐渐显现,并被引入自然语言处理领域。郭瑞等人^[8]提出基于 RoBERTa 和对抗训练的中文命名实体识别模型,有效解决了 BERT 在中文处理中分词不稳定等问题,展现出较强的泛化能力。Dong 等人^[9]结合 BERT 和对抗训练,显著提升了食品领域非结构化语料的实体抽取精度。李文焱等人^[10]通过对抗训练强化对易错样本的学习,提出实体关系联合抽取模型,大幅提高了模型对新样本的适应性与稳健性。对抗训练的应用显著增强了模型的鲁棒性与泛化能力,为解决局部不稳定性等问题提供了有效思路。

1.3 多头自注意力机制

多头自注意力机制是 Transformer 架构中的核心组成部分,也是 NLP 领域取得显著进展的关键技术之一。它是自注意力机制的扩展,通过并行计算多个注意力头,能够捕捉输入序列中的多维语义信息,进而提升模型在复杂任务中的表现。He 等人^[11]传统方法在多义词处理和语义建模方面受到限制,但 BERT-BiLSTM-Att-CRF 模型在简历数据集上表现良好。Hao 等人^[12]提出结合 RoBERTa-wwm、多头自注意力与 BiLSTM 的特征提取方法,通过 CRF 完成标注,在“CCKS 2019”数据集上显著提升了 F1 分值。

尽管对抗训练和注意力机制已在多个领域得到广泛应用,但将二者结合的研究仍较为有限,尤其是在 MOOC 评论的方面词抽取任务中。现有研究主要侧重单一技术的应用。然而,本文首次将对抗训练与多头自注意力机制相结合,提出了一种更加鲁棒且精确的方面词抽取模型。这一创新性结合使得模型能够有效应对 MOOC 评论中的噪声数据和语言多样性,同时处理长文本中的长距离依赖问题,确保了语义信息的准确传递。

2 RAMB 模型

本文提出的方面词抽取模型 RAMB 的结构如图 1 所示,包含五个模块:RoBERTa-wwm 词嵌入层、对抗训练模块(AT)、BiLSTM 层、多头自注意力层和 CRF 层。整体处理流程为:首先,利用 RoBERTa-wwm 提取文本语义向量;其次,通过对抗训练生成扰动样本,并与原始词向量一同输入 BiLSTM 网络;接着,使用多头自注意力机制分配标签权重;最后,CRF 层优化目标函数,基于上下文信息进行标签预测。

2.1 RoBERTa-wwm 词嵌入层

本文采用 RoBERTa-wwm 模型作为文本表示模型,该模型由 12 个 Transformer 层构成,并采用全词掩码策略,即掩码词内所有字而非单个字,且移除了下一句预测任务,从而提高了训练效率和语义理解能力。与 BERT 相比,RoBERTa-wwm 利用更大规模的预训练

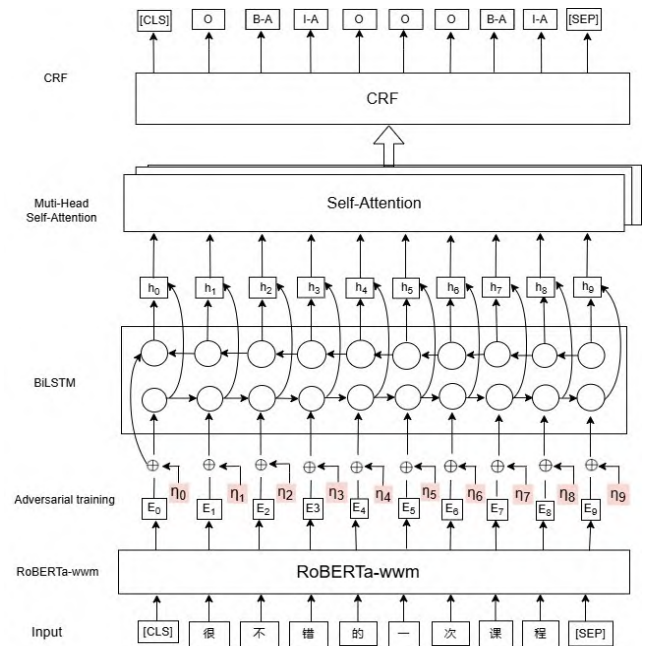


图 1 RAMB 模型结构图

数据集、更长的训练步数和更长的序列长度,增强了模型对 MOOC 评论中语义特征的学习能力。定义输入语句为 $s=\{x_1,x_2,\dots,x_n\}$,其中 x_n 表示句子中的第 n 个字。

在句子的起始位置加入 [CLS] 标签,在句子的结尾加入 [SEP] 标签,经过预训练模型 RoBERTa-wwm 处理后得到输入句子 s 的初始向量表示为 $\{E_0,E_1,E_2,\dots,E_n,E_{n+1}\}$ 。

2.2 对抗训练

对抗训练是一种在训练过程中引入噪声的方法,通过对模型的可学习参数进行正则化提升模型的泛化能力^[13]。例如,Dropout 通过引入随机噪声来正则化模型,而对抗训练则通过在模型的向量表示中添加扰动,生成对抗样本。这些对抗样本是原始样本的变体,具有较强的误导模型的潜力。研究表明,通过在训练数据中引入微小的扰动,对抗训练可以显著提升神经网络模型的鲁棒性,使其在面对挑战性输入时更具稳定性。在 RAMB 模型中,把经过 RoBERTa-wwm 处理之后获得的初始向量表示 $\{E_0,E_1,E_2,\dots,E_n,E_{n+1}\}$ 定义为 E ,添加的扰动定义为 η_{adv} ,其计算公式如下:

$$\eta_{adv} = \varepsilon g / \|g\|_2 \tag{1}$$

$$g = \nabla_E L(E; \theta) \tag{2}$$

其中: θ 是模型参数, ε 是一个可调的超参数, g 指梯度, $\|g\|_2$ 指对嵌入矩阵求二范数从而得到一个作为分母的标量, L 为当前样本的损失;扰动 η_{adv} 是在显著增加损失的方向上产生的。将对抗样本定义为 E_{adv} ,其计算公式为:

$$E_{adv} = E + \eta_{adv} \tag{3}$$

在生成对抗样本后,模型将原始向量 E 与对抗样本 E_{adv} 一同输入 BiLSTM 训练,有效提升模型在复杂数据环境下的稳定性。

2.3 BiLSTM 全局特征提取

MOOC 课程评论常面临文本长度不均、上下文信

息不足以及噪声干扰等挑战。在方面词抽取任务中,传统RNN在处理长距离依赖时存在局限,仅能单向捕捉上下文,并易受梯度消失问题影响^[14]。LSTM通过门控机制有效缓解了这些问题,提升了对长距离依赖的建模能力。而BiLSTM通过双向处理序列,全面捕捉前后文信息,增强了对文本特征的提取与整合。每个LSTM层包含256个隐藏单元,通过拼接前向和反向输出,生成更为丰富的上下文表示。

本文采用双向长短期记忆网络^[15]以充分利用输入的上下文信息。将原始向量表示E和对抗样本E_{adv}一同输入BiLSTM后的计算公式如下:

$$g_i = \sigma(W_i \cdot [E + E_{adv}; h_{i-1}] + b_i) \tag{4}$$

$$o_i = \sigma(W_o \cdot [E + E_{adv}; h_{i-1}] + b_o) \tag{5}$$

$$f_i = \sigma(W_f \cdot [E + E_{adv}; h_{i-1}] + b_f) \tag{6}$$

$$\tilde{c}_i = \tanh(W_c \cdot [E + E_{adv}; h_{i-1}] + b_c) \tag{7}$$

$$c_i = f_i \odot c_{i-1} + i_i \odot \tilde{c}_i \tag{8}$$

$$h_i = o_i \odot \tanh(c_i) \tag{9}$$

其中: g_i, o_i, f_i 分别表示*i*时刻的输入门、输出门、遗忘门; c_i 为计算的中间结果; W 和**b**为参数; h_{i-1} 表示字*x_{i-1}*的隐藏层输出; σ 为Sigmoid激活函数,用于门控机制的计算。

2.4 多头自注意力机制

在MOOC课程评论语料中,尽管BiLSTM能够有效捕捉长距离和全局信息,但在局部特征识别上存在局限,尤其是对“作业”“单元测试”中的具体知识点和课程互动等实体的识别,这些实体的边界较难明确界定。为解决这一问题,引入了多头自注意力机制^[16],以增强模型对上下文信息的关注,精确识别实体边界。具体而言,多头自注意力机制通过计算每个词与其他词之间的相似度(基于查询、键、值的内积),并对相似度进行softmax归一化,得到注意力权重。例如,在句子“作业、单元测试中的知识点覆盖全面,课程互动做得也非常好”中,词“作业”可能对“知识点”赋予较高的权重(如0.4),而对“课程互动”则赋予较低的权重(如0.1)。具体公式如下:

$$Attention(Q,K,V) = \text{soft max} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \tag{10}$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \tag{11}$$

其中, d_k 表示查询向量和键向量的维度, $\sqrt{d_k}$ 作为惩罚因子,用于避免缩放点和结果过大。

2.5 CRF

条件随机场(CRF)是一种基于最大熵模型和隐马尔科夫模型的判别式概率模型,广泛应用于序列数据分析。BiLSTM主要捕捉上下文信息,而注意力层虽然对输入进行加权,但未充分考虑标签间的连续依赖性。因此,本文将注意力层输出的向量传入CRF层进行标签序列预测。CRF通过学习相邻标签之间的约束关系,优化预测结果,避免生成不符合逻辑的标签序列,从而提升模型的准确性。例如,标签“**I**”只能跟随标签“**B**”出现,而不能作为序列的起始标签。

对于给定的文本序列 $X=(x_1, x_2, \dots, x_n)$ 及其对应的预测标签序列 $Y=(y_1, y_2, \dots, y_n)$,定义CRF的评估分数为:

$$Score(x,y) = \sum_{i=0}^n A_{y_i, y_{i+1}} + \sum_{i=1}^n P_{i, y_i} \tag{12}$$

3 实验设置

3.1 数据集获取与预处理

数据集来源于中国大学慕课平台,采用网络爬虫工具结合Selenium模拟用户登录与交互操作,并利用BeautifulSoup进行网页解析。共采集了7门课程(软件工程、计算机网络、数据库原理、操作系统、人工智能、数据结构与算法、编译原理)的3 840条评论,涵盖课程内容、教学质量、教材使用、授课方式及作业难度等方面。数据收集后进行了预处理,剔除了口语化表述、重复项及非法字符。

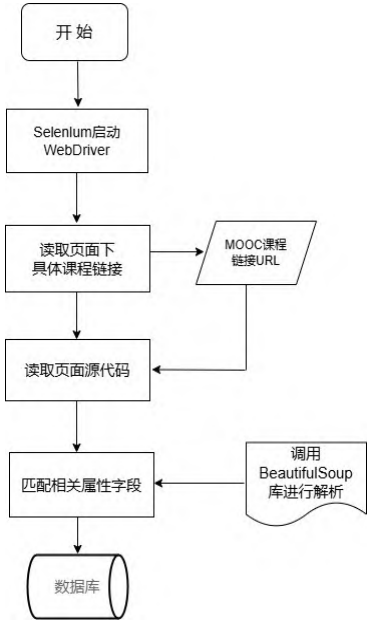


图2 数据爬取流程

3.2 数据集的标注

预处理后的数据为纯文本,需对方面词进行细粒度情感分析标注。本文采用BIO标记方法对方面词进行标注,其中B-ASP表示方面词短语的起始词,I-ASP表示其内部词,O表示非方面词。此外,情感极性标注为Positive和Negative。具体标注示例如表1所示,按照此标准,对约3 840条评论进行了标注处理。

表1 序列标记示例

这门	课程	内容	非常	精彩
O	B-ASP	I-ASP	O	O
	Positive	Positive		
但	作业	部分	有点	难度
O	B-ASP	I-ASP	O	O
	Negative	Negative		

3.3 数据统计信息

数据标注后,整理出3 840条评论,构建为实验数据集。为增强实验可信度,本文将其与已有数据集(MOOC1、MOOC2)进行对比,按7:2:1比例划分为训练集、验证集和测试集,分别用于特征学习、超参数优

化与模型评估,如表 2 所示。

表 2 实验数据集信息统计

数据集		MOOC 1	MOOC 2
训练数据集	评论数	2 688	2 002
	方面词个数	4 848	4 004
验证数据集	评论数	768	572
	方面词个数	1 344	1 144
测试数据集	评论数	384	286
	方面词个数	608	572

3.4 实验参数设置

模型训练时主要考虑到的超参数如表 3 所示。

表 3 实验参数设置

实验参数	参数值
学习率	3e-5
CRF 层学习率	1e-4
优化器	Adam
Batch size	32
Training Epochs	20
Dropout Rate	0.5
最大序列长度	128
注意力机制头数	8

4 实验结果与分析

4.1 不同模型对比实验

为了有效评估 RAMB 模型,选取了多种具有代表性的主流模型作为基线,并在自建的 MOOC 课程评论数据集上进行了对比实验。实验结果如表 4 所示。

(1) TextCNN:该模型使用卷积神经网络(CNN) 进行相关标注。

(2) BiLSTM:该模型是 BERT 的基础模型,通过下游微调能够进行各种任务。

(3) BiLSTM-CRF:以预训练语言模型 BERT 完成文本嵌入生成向量后由 CRF 进行标签解码的实体识别模型

(4) BERT-BiLSTM-CRF:选用预训练语言模型 BERT 完成文本嵌入,利用 BiLSTM 提取特征,并通过 CRF 完成实体标签识别的模型

(5) RoBERTa-BiLSTM-CRF:采用动态掩码和大规模参数的预训练语言模型 RoBERTa 完成文本嵌入,通过 BiLSTM 捕获序列特征,并利用 CRF 进行实体识别。

(6) RAMB:本文提出的基于对抗训练和注意力机制的方面词提取模型。

表 4 MOOC 评论数据集结果对比(%)

Method	MOOC 1		MOOC 2	
	Accuracy	F1	Accuracy	F1
TextCNN	82.32	71.84	79.56	68.14
BiLSTM	84.61	74.28	82.23	72.14
BiLSTM-CRF	86.74	77.42	84.91	76.38
BERT-BiLSTM-CRF	90.17	80.51	88.23	79.04
RoBERTa-BiLSTM-CRF	91.82	83.27	89.86	81.72
RAMB	93.13	85.72	91.24	84.11

实验结果表明,随着模型复杂度的增加,准确率和 F1 值均显著提升,反映出更复杂的模型在方面词抽取任务中的优势。TextCNN 主要依赖局部特征,尽管在初步评估中取得较好的表现,但在处理长程依赖和复杂上下文时能力有限。引入 BiLSTM 后,模型能够捕捉双向上下文信息,性能有所改善,尤其在 MOOC1 数据集上。然而,对于标签间的依赖关系仍缺乏有效建模。通过增加 CRF 层,BiLSTM-CRF 优化了标签序列的预测,显著提高了准确率和 F1 值,尤其在 MOOC2 数据集上表现突出。进一步优化的 BERT-BiLSTM-CRF 模型利用 BERT 的预训练能力,提升了语义理解和上下文处理能力,尤其在复杂文本中展现出明显优势。RoBERTa-BiLSTM-CRF 在 BERT 的基础上通过动态掩码策略提升了鲁棒性,进一步提升了模型在 MOOC1 数据集集中的表现。最后,RAMB 通过引入多头自注意力机制,精细化加权上下文信息,显著提升了对复杂文本和实体边界的识别能力,最终在两组数据集上均取得了最佳性能。

4.2 特征消融实验

为了进一步验证本文模型加入对抗训练和多头自注意力机制的有效性,设计消融实验。将 RoBERTa-BiLSTM-CRF 模型作为基准模型,将模型增加对抗训练记为“+AT”,将模型增加多头自注意力机制记为“+MHSA”,消融实验结果如表 5 所示。

表 5 在 MOOC 评论数据集上的消融实验结果(%)

Modle	MOOC1		MOOC2	
	Accuracy	F1	Accuracy	F1
RoBERTa-BiLSTM-CRF	91.82	83.27	89.82	81.22
+AT	92.45	84.11	90.58	82.35
+MHSA	92.90	84.75	91.10	83.11
RAMB	93.13	85.72	91.75	84.20

与基准模型相比,引入对抗训练显著提升了模型对多样化数据的适应性,有助于更精准地学习区分性特征。具体表现为,准确率提升至 92.45%,F1 值提高至 84.11%。在此基础上,结合多头自注意力机制进一步强化了模型对句子语义关键区域的关注。最终,融合对抗训练与多头自注意力机制的 RAMB 模型实现了最佳性能,准确率达到 93.13%,F1 值提升至 85.72%。结果表明,这两种技术的结合显著优化了 MOOC 评论方面词抽取的表现。

5 结束语

为了有效提取 MOOC 课程评论中的方面词,本文提出一种融合对抗训练和多头注意力机制的模型。对抗训练通过生成扰动样本,增强模型在复杂数据环境中的鲁棒性;而多头自注意力机制则有效捕捉局部与全局语境,精确识别方面词的边界。实验结果表明,该模型在 MOOC 评论数据集上优于传统基准模型,显著提升了精确度和稳健性。未来,模型可拓展应用至医疗、金融等领域,探索其适用性与效果,也可结合智能搜索和问答系统,为用户提供更智能、个性化的服务。下一步,研究将聚焦于构建跨模态实体抽取技术,结合文本、图像、视频等多种数据源,进一步

提升方面词抽取的准确性与适用性。

参考文献:

- [1] 潘芳,张会兵,董俊超.基于激活-池化增强BERT模型的在线课程评论情感分析[J].计算机应用与软件,2021,38(5):183-189.
- [2] 陈怀博,张会兵,首照宇,等.融合多语言知识的慕课评论隐式方面情感分析[J].计算机工程与应用,2025,61(05):104-112.
- [3] 白友恒,肖奎,张葵,等.基于深度学习模型的MOOC视频依赖关系识别方法[J].郑州大学学报(理学版),2022,54(5):29-36.
- [4] LI J, SUN A X, HAN J L, et al. A survey on deep learning for named entity recognition[J]. IEEE Transactions on Knowledge and Data Engineering, 34(1):50-70.
- [5] HUANG Z H, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[EB/OL]. 2015: 1508.01991. <https://arxiv.org/abs/1508.01991v1>.
- [6] LIU S, YANG H, LI J Y, et al. Chinese named entity recognition method in history and culture field based on BERT[J]. International Journal of Computational Intelligence Systems, 2021, 14(1):163.
- [7] GOODFELLOW I J, SHLENS J, SZEGEDY C, et al. Explaining and harnessing adversarial examples[EB/OL]. 2014: 1412.6572. <https://arxiv.org/abs/1412.6572v3>.
- [8] 郭瑞,张欢欢.基于RoBERTa和对抗训练的中文医疗命名实体识别[J].华东理工大学学报(自然科学版),2023,49(1):144-152.
- [9] DONG Z, SHAO R Q, CHEN Y L, et al. Named entity recognition in the food field based on BERT and Adversarial training[C]// 2021 33rd Chinese Control and Decision Conference(CCDC). May 22-24, 2021. Kunming, China. IEEE, 2021: 2219-2226.

- [10] 李文炽,刘远兴,蔡泽宇,等.融合对抗训练及全局指针的实体关系联合抽取[J].计算机系统应用,2024,33(6):91-98.
- [11] HE W L, XU Y L, YU Q L. BERT-BiLSTM-CRF Chinese resume named entity recognition combining attention mechanisms[C]//Proceedings of the 4th International Conference on Artificial Intelligence and Computer Engineering. Dalian China. ACM, 2023: 542-547.
- [12] HAO P Y, ZHANG L. Chinese electronic medical records named entity recognition based on RoBERTa-wwm and Multi-Head attention[C]//2024 IEEE 3rd International Conference on Electrical Engineering, Big Data and Algorithms (EEBDA). February 27-29, 2024. Changchun, China. IEEE, 2024: 1022-1026.
- [13] MIYATO T, DAI A M, GOODFELLOW I. Adversarial training methods for semi-supervised text classification[EB/OL]. 2016: 1605.07725. <https://arxiv.org/abs/1605.07725v4>.
- [14] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[EB/OL]. 2014: 1406.1078. <https://arxiv.org/abs/1406.1078v3>.
- [15] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural architectures for named entity recognition[EB/OL]. 2016: 1603.01360. <https://arxiv.org/abs/1603.01360v3>.
- [16] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J]. arXiv, 2017. <https://arxiv.org/abs/1706.03762>.

【通联编辑:王力】

(上接第8页)

流建模及领域增强型缺陷检测算法,对芯片设计、固件及软件源码进行分析,能够高效地检测出源代码中可能导致严重漏洞和系统运行异常的安全问题以及程序缺陷,并准确定位告警。通过静态分析,可以在开发早期发现潜在的设计缺陷和安全漏洞,从而显著提高芯片的可靠性和安全性。

5 总结

芯片的发展在物联网、智能汽车、人工智能、军工航天等领域的地位日益重要。然而,纵观国内芯片供应链安全现状,仍存在诸多风险。通过物理安全检测、软件与固件安全检测两个方向的芯片供应链安全检测方法,可以有效检测和防范芯片供应链安全问题,在一定程度上提升芯片的安全性和可靠性。当前,国内芯片供应链安全的抗风险能力仍急需提升,在突破和创新核心技术的同时,还要应对复杂的国际竞争环境。

参考文献:

- [1] 赵荣杰,房超.芯片领域科技安全现状与对策[J].科技导报,

2023,41(6):55-61.

- [2] 王小强,邓传锦,范剑峰.集成电路发展历程,现状和建议[J].电子产品可靠性与环境试验,2021,39(S1):6.
- [3] 李永明,郭衍亮,郭永海.汽车芯片产业风险的破解[J].唯实,2021(12):23-27.
- [4] 倪红福,张志达.全球价值链重构与提高产业链供应链稳定性[J].清华金融评论,2022(10):48-51.
- [5] 曾晓翔.美国供应链安全联盟影响下的芯片产业布局变化[J].统一论坛,2022(2):25-29.
- [6] 刘伟华,王钰杰,袁超伦.高新技术产业供应链安全保障和维护策略:以芯片产业为例[J].供应链管理,2023,4(7):5-16.
- [7] 顾旭辉.芯片硬件后门物理场特征分析与隐藏技术研究[D].成都:电子科技大学,2022.
- [8] 中国网络空间安全协会.漏洞频发、故障率高 应系统排查英特尔产品网络安全风险[EB/OL]. [2024-10-16]. <https://www.cybersac.cn/detail/1846721771810627586>.
- [9] Nitrokey. Smartphones With Popular Qualcomm Chip Secretly Share Private Information With US Chip-Maker[EB/OL]. [2023-05-06]. <https://www.nitrokey.com/news/2023/smartphones-popular-qualcomm-chip-secretly-share-private-information-us-chip-maker>.

【通联编辑:谢媛媛】